



Univerzitet u Beogradu
Matematički fakultet

Seminarski rad

Analiza Amazon recenzija primenom tehnika istraživanja podataka

(Klasifikacija, klasterovanje i pravila pridruživanja)

Mentor:

Prof. dr Mirjana Maljković Ružičić
Katedra za računarstvo i informatiku

Studenti:

Dragana Katić 91/2021
Tamara Šaponjić 252/2021
Smer: Informatika

Datum: Februar 2026

Sadržaj

1	Uvod	3
2	Opis zadatka	3
3	Opis skupa podataka	3
3.1	Ciljne promenljive	4
3.2	Balansiranje podataka	4
4	Preprocesiranje podataka	4
4.1	Obrada teksta	4
5	Analiza podataka i metodološke pretpostavke	5
5.1	Karakteristike skupa podataka	5
5.2	Visoka dimenzionalnost i redukcija dimenzionalnosti	5
5.3	Struktura problema	7
5.4	Uticaj nebalansiranosti podataka	7
5.5	Zaključak analize podataka	7
6	Klasifikacija	8
6.1	Skupovi atributa i redukcija dimenzionalnosti	8
6.2	Balansiranje podataka	8
6.3	Podela podataka	9
6.4	Korišćeni algoritmi	9
6.4.1	LinearSVC	9
6.4.2	Logistic Regression	9
6.4.3	SGDClassifier (hinge)	9
6.4.4	Random Forest	10
6.4.5	Complement Naive Bayes	10
6.5	Metrike evaluacije	10
6.6	Rezultati za cilj <i>Score</i>	11
6.6.1	Rezultati nad ALL atributima	11
6.6.2	Optimizacija i validacija najboljeg modela	12
6.6.3	Najinformativnije reči po klasama – cilj <i>Score</i>	13
6.6.4	Rezultati nad Text-only skupom	14
6.6.5	Poređenje Text-only vs ALL atributi	15
6.6.6	Analiza matrica konfuzije – cilj <i>Score</i>	16
6.7	Rezultati za cilj <i>Sentiment</i>	18
6.7.1	Rezultati nad ALL atributima	19
6.7.2	Rezultati nad Text-only skupom	21
6.7.3	Analiza matrica konfuzije – cilj <i>Sentiment</i>	22
6.7.4	ROC kriva i AUC metrika	24
6.8	Poređenje cilja <i>Score</i> i cilja <i>Sentiment</i>	24
6.9	Zaključak klasifikacije	25

7	Klasterovanje	26
7.1	Metrike evaluacije	26
7.2	Primenjeni algoritmi	27
7.2.1	K-Means	27
7.2.2	MiniBatch K-Means	27
7.2.3	Agglomerative Clustering	27
7.2.4	Spectral Clustering	27
7.2.5	DBSCAN	27
7.3	Određivanje optimalnog broja klastera	27
7.4	Klasterovanje – svi atributi	28
7.4.1	Opis skupa atributa	28
7.4.2	Određivanje optimalnog K	28
7.4.3	Rezultati	28
7.4.4	Analiza DBSCAN rezultata	29
7.4.5	Vizualizacija	29
7.4.6	Interpretacija klastera ($K = 2$)	30
7.4.7	Interpretacija klastera ($K = 5$)	31
7.5	Klasterovanje – samo tekst	31
7.5.1	Opis skupa atributa	31
7.5.2	Određivanje optimalnog K	32
7.5.3	Rezultati	32
7.5.4	Analiza DBSCAN rezultata	32
7.5.5	Vizualizacija	33
7.5.6	Interpretacija klastera ($K = 8$)	34
7.6	Klasterovanje – redukovani atributi (SVD)	34
7.6.1	Opis skupa atributa i SVD redukcija	34
7.6.2	Određivanje optimalnog K	35
7.6.3	Rezultati	35
7.6.4	Analiza DBSCAN rezultata	35
7.6.5	Vizualizacija	36
7.6.6	Interpretacija klastera ($K = 8$)	37
7.7	Poređenje modela klasterovanja	37
7.7.1	Poređenje po metrikama	37
7.7.2	Ključni zaključci poređenja	38
7.8	Zaključak klasterovanja	39
8	Pravila pridruživanja	39
8.1	Formiranje transakcija	39
8.2	Apriori algoritam i parametri	40
8.3	Rezultati	40
8.4	Zaključak pravila pridruživanja	42
9	Zaključak rada	42

1 Uvod

Skupovi podataka koji sadrže korisnički generisan tekst predstavljaju važan izvor informacija, ali istovremeno i izazov za obradu zbog velike dimenzionalnosti i šuma u jeziku. U ovom radu analiziran je skup *Amazon reviews* primenom tehnika istraživanja podataka nad tekstualnim i numeričkim atributima.

Ciljevi rada su:

- izrada klasifikacionih modela za višeklasni cilj (**Score**) i binarni cilj (**Sentiment**),
- nenadgledana analiza pomoću klasterovanja nad različitim skupovima atributa (tekstualni, redukovani i kombinovani),
- otkrivanje pravila pridruživanja (market-basket) nad korisnicima i proizvodima.

Poseban fokus je na (i) obradi teksta (TF-IDF), (ii) poređenju modela nad nebalansiranim (RAW) i balansiranim (BAL) skupom, kao i (iii) uticaju redukcije dimenzionalnosti (SVD) na klasterovanje i vizualizaciju.

2 Opis zadatka

U okviru projekta realizovani su sledeći koraci (u skladu sa uputstvom):

- analiza i razumevanje skupa podataka,
- preprocesiranje i priprema podataka,
- klasifikacija nad različitim skupovima atributa,
- klasterovanje nad različitim skupovima atributa,
- 2D/3D vizualizacija podataka,
- pravila pridruživanja (Apriori),
- analiza i poređenje dobijenih rezultata.

3 Opis skupa podataka

Skup podataka sadrži korisničke recenzije proizvoda sa Amazon platforme. Ključne kolone koje se koriste u projektu su:

- **Score** – ocena proizvoda (1–5),
- **Summary** i **Text** – tekst recenzije (kratak i pun tekst),
- **HelpfulnessNumerator** i **HelpfulnessDenominator**,
- **ProductId** i **UserId** (za pravila pridruživanja).

3.1 Ciljne promenljive

U radu su korišćena dva različita cilja klasifikacije:


- **Višeklasna klasifikacija: Score** (5 klasa).
- **Binarna klasifikacija: Sentiment**. Sentiment je izveden iz Score:

negativno (0) : $Score \leq 2$, pozitivno (1) : $Score \geq 4$,

pri čemu su recenzije sa $Score = 3$ uklonjene.

3.2 Balansiranje podataka

Skup podataka je inicijalno nebalansiran (dominira viša ocena).



Slika 1: Distribucija ocena (Score) u skupu podataka

Zbog toga su eksperimenti rađeni:

- **RAW**: originalna distribucija klasa,
- **BAL**: balansirana verzija (random undersampling do veličine najmanje klase).

Za nebalansirane podatke koristi se metrika **F1-macro**, jer jednako vrednuje sve klase bez obzira na njihovu učestalost.

4 Preprocesiranje podataka

4.1 Obrada teksta

Tekst iz kolona Summary i Text je očišćen i normalizovan:

- pretvaranje u mala slova,
- uklanjanje URL-ova i specijalnih karaktera,

- tokenizacija i uklanjanje stop-reči,
- lematizacija.

Nakon toga, tekst je predstavljan pomoću TF-IDF vektorizacije sa bigramima (uni-grams + bigrams).

5 Analiza podataka i metodološke pretpostavke

Pre primene nadgledanih i nenadgledanih tehnika izvršena je analiza strukture podataka i njihovih karakteristika, sa ciljem razumevanja prirode problema i definisanja odgovarajućih metodoloških pristupa.

5.1 Karakteristike skupa podataka

Eksploratorna analiza pokazuje sledeće osobine skupa:

- Skup je izrazito **nebalansiran** po pitanju ciljne promenljive Score, pri čemu dominira ocena 5.
- Tekstualni podaci su **heterogeni po dužini**, sa izraženom desnom asimetrijom distribucije.
- TF-IDF reprezentacija generiše **visoko-dimenzionalan i redak prostor osobina**.


Ove karakteristike imaju direktan uticaj i na klasifikaciju i na klasterovanje.

5.2 Visoka dimenzionalnost i redukcija dimenzionalnosti


Primena TF-IDF reprezentacije nad tekstualnim podacima rezultira matricom velikog broja atributa (10 000 i 20 000 osobina). Takva reprezentacija je pogodna za klasifikaciju, ali otežava:

- vizualizaciju podataka,
- primenu algoritama klasterovanja osetljivih na dimenzionalnost,
- interpretaciju rezultata.

Zbog toga je u radu primenjena metoda **Truncated SVD** radi redukcije dimenzionalnosti i dobijanja projekcija u 2D i 3D prostoru. Analiza projekcija pokazuje snažno preklapanje klasa i odsustvo jasno separisanih klastera u prostoru prvih nekoliko komponenti.



Slika 2: 3D projekcija TF-IDF prostora pomoću TruncatedSVD



Slika 3: 2D projekcija TF-IDF prostora pomoću TruncatedSVD

Sa slika 2 i 3 može se uočiti izraženo preklapanje klasa u prostoru prvih nekoliko

SVD komponenti. Klase nisu jasno separisane, već formiraju gust, međusobno isprepletan raspored tačaka.

Ovakva struktura ukazuje da razlike između recenzija nisu koncentrisane u malom broju dominantnih dimenzija, već su raspodeljene kroz veći broj osobina. Posledično, problem zahteva algoritme koji su sposobni da modeluju suptilne i kompleksne obrasce u visoko-dimenzionalnom prostoru.

5.3 Struktura problema

Problem u ovom radu ima dve dimenzije:

- **Nadgledana analiza (klasifikacija)** – predviđanje ocene ili sentimenta na osnovu atributa.
- **Nenadgledana analiza (klasterovanje)** – grupisanje recenzija bez unapred definisanih oznaka.

S obzirom na preklapanje klasa u redukovanom prostoru, očekuje se da klasteri neće u potpunosti odgovarati klasama Score, što omogućava dodatnu analizu strukture podataka nezavisno od ciljne promenljive.

5.4 Uticaj nebalansiranosti podataka

Neravnomerna raspodela klasa utiče prvenstveno na klasifikaciju, jer modeli mogu favorizovati dominantne klase. Zbog toga su eksperimenti realizovani nad:

- originalnim (RAW) skupom,
- balansiranim (BAL) skupom dobijenim metodom undersampling-a.

Kod klasterovanja, nebalansiranost se ne tretira direktno, ali može uticati na veličinu i interpretaciju dobijenih klastera.

5.5 Zaključak analize podataka

Na osnovu analize može se zaključiti:

- podaci su visoko-dimenzionalni i retki,
- klase su međusobno preklapljene,
- ne postoji jednostavna linearna separacija u prostoru malog broja komponenti,
- očekuje se da će različiti algoritmi pokazivati različite performanse u zavisnosti od izbora atributa i balansiranja podataka.

Ovi zaključci predstavljaju osnovu za primenu i poređenje klasifikacionih i metoda klasterovanja u nastavku rada.

6 Klasifikacija

U ovom poglavlju prikazana je nadgledana analiza Amazon recenzija primenom više klasifikacionih algoritama. Eksperimenti su sprovedeni za dva cilja:

- **Višeklasna klasifikacija** – predikcija ocene **Score** (1–5),
- **Binarna klasifikacija** – predikcija **Sentiment**-a (negativno / pozitivno).

Cilj je izgradnja modela koji na osnovu tekstualnog sadržaja i dodatnih numeričkih atributa može pouzdano predvideti ocenu ili sentiment nove recenzije.

Za evaluaciju modela korišćena je stratifikovana podjela podataka na trening i test skup (80/20). Za najbolji model dodatno je primenjena **5-fold cross-validation** na trening skupu radi stabilnije procene performansi.

6.1 Skupovi atributa i redukcija dimenzionalnosti

Eksperimenti su sprovedeni nad dva skupa osobina:

- **Text-only** – samo tekstualne osobine predstavljene TF-IDF vektorima,
- **ALL** – kombinacija tekstualnih i numeričkih osobina.

Tekstualne osobine dobijene su primenom TF-IDF vektorizacije sa bigramima, u dve konfiguracije:

- **TFIDF_10k** – maksimalno 10 000 osobina,
- **TFIDF_20k** – maksimalno 20 000 osobina.

Kod Text-only eksperimenta dodatno je primenjena **TruncatedSVD redukcija dimenzionalnosti** nad TF-IDF (10k), sa $k = 300$ komponenti.

Cilj primene SVD redukcije bio je smanjenje dimenzionalnosti prostora, uklanjanje redundantnih informacija i ubrzanje treniranja modela.

Kod ALL skupa korišćene su sledeće numeričke osobine:

- `HelpfulnessNumerator`,
- `HelpfulnessDenominator`,
- `HelpfulnessRatio`.

Numeričke osobine su skalirane kako bi bile kompatibilne sa TF-IDF reprezentacijom.

6.2 Balansiranje podataka

Distribucija cilja **Score** je izrazito neuravnotežena, sa dominantnom klasom 5. Zbog toga su eksperimenti sprovedeni nad:

- **RAW** – originalna distribucija,
- **BAL** – balansirana verzija dobijena metodom undersampling-a.

Kod neuravnoteženih podataka glavna metrika poređenja modela bila je **F1-macro**, jer bolje odražava performanse na svim klasama.

6.3 Podela podataka

Podaci su podeljeni na trening i test skup korišćenjem stratifikovane podele (train/test split), kako bi odnos klasa bio očuvan u oba skupa.

Za svaku konfiguraciju (RAW/BAL, Text/ALL, Score/Sentiment) model je treniran na trening skupu, a evaluiran na test skupu.

6.4 Korišćeni algoritmi

Izabrani su algoritmi različite prirode: linearni modeli (LinearSVC, Logistic Regression), model optimizovan stohastičkim učenjem (SGD), probabilistički pristup (Complement Naive Bayes) i ansambl metoda zasnovana na stablima (Random Forest). Na ovaj način analiziran je uticaj tipa modela na performanse u visoko-dimenzionalnom tekstualnom prostoru.

6.4.1 LinearSVC

LinearSVC implementira Support Vector Machine sa linearnim kernelom. Algoritam traži hiperravan koja maksimalno razdvaja klase u visoko-dimenzionalnom prostoru.

Očekivanja:

- vrlo dobre performanse na tekstualnim podacima visoke dimenzionalnosti,
- robustnost na veliki broj osobina (TF-IDF prostor).

U eksperimentima je LinearSVC pokazao stabilne i visoke vrednosti tačnosti i F1-score, naročito na tekstualnom skupu.

6.4.2 Logistic Regression

Logistička regresija modeluje verovatnoću pripadnosti klasi pomoću linearne kombinacije osobina.

Očekivanja:

- dobre performanse u linearnim, visoko-dimenzionalnim prostorima,
- stabilnost i interpretabilnost.

U praksi je Logistic Regression često bila među najboljim modelima, posebno u balansiranim eksperimentima.

6.4.3 SGDClassifier (hinge)

SGDClassifier sa hinge loss funkcijom predstavlja aproksimaciju linearnog SVM-a treniranog metodom stohastičkog gradijentnog spusta.

Očekivanja:

- brže treniranje na velikim skupovima,
- nešto niže, ali konkurentne performanse u odnosu na LinearSVC.

Rezultati su pokazali da je SGD nešto osetljiviji na podešavanje parametara i balans podataka.

6.4.4 Random Forest

Random Forest je ansambl metoda zasnovana na više stabala odlučivanja. Očekivanja:

- bolje performanse na kombinovanim (ALL) atributima,
- slabije performanse u veoma visoko-dimenzionalnom TF-IDF prostoru.

U eksperimentima se pokazalo da Random Forest nije optimalan za čisto tekstualne podatke velike dimenzionalnosti, ali može imati bolje rezultate kada su uključene numeričke osobine.

6.4.5 Complement Naive Bayes

Complement Naive Bayes je varijanta Naive Bayes algoritma optimizovana za nebalansirane tekstualne podatke.

Očekivanja:

- dobre performanse na tekstualnim podacima,
- brza obuka,
- nešto slabije performanse od linearnih modela.

U eksperimentima je pokazao solidne rezultate, ali je uglavnom bio inferioran u odnosu na LinearSVC i Logistic Regression.

6.5 Metrike evaluacije

Kvalitet klasifikacije evaluiran je sledećim metrikama:

Accuracy meri ukupan udeo ispravno klasifikovanih instanci u odnosu na ukupan broj instanci:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

Precision meri koliki udeo instanci koje je model označio kao pozitivne zaista jesu pozitivne:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2)$$

Recall meri koliki udeo stvarno pozitivnih instanci je model uspešno detektovao:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3)$$

F1-score harmonijska sredina preciznosti i odziva, koja pruža balansiranu meru kvaliteta klasifikacije:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$

Računat je u dve varijante:

- *Macro* – računa F1 nezavisno za svaku klasu i uzima neponderisani prosek, tretujući sve klase podjednako.

- *Weighted* – uzima težinski prosek prema broju instanci po klasi.

ROC-AUC korišćen isključivo u slučaju binarne klasifikacije, meri površinu ispod ROC krive koja prikazuje odnos između stope tačno pozitivnih (*TPR*) i stope lažno pozitivnih (*FPR*) za različite pragove odlučivanja. Vrednost bliža 1 ukazuje na bolji model.

Kod nebalansiranih skupova podataka, primarna metrika za poređenje modela bila je **F1-macro**, s obzirom na to da jednako vrednuje performanse modela po svim klasama, nezavisno od njihove zastupljenosti.

6.6 Rezultati za cilj *Score*

6.6.1 Rezultati nad ALL atributima

Tabela 1 prikazuje rezultate svih modela nad skupom svih atributa (tekst + numerički), za obe TF-IDF konfiguracije i oba balansiranja (RAW i BAL).


Tabela 1: Rezultati klasifikacije – cilj Score, ALL atributi

#	Dataset	TFIDF	Model	Accuracy	F1-macro	F1-weighted
1	RAW	20k	LinearSVC	0.7360	0.5212	0.7130
2	RAW	10k	LinearSVC	0.7337	0.5170	0.7088
3	BAL	20k	Random forest	0.6440	0.4887	0.6615
4	RAW	10k	LogReg	0.7350	0.4830	0.6942
5	BAL	20k	LogReg	0.6107	0.4829	0.6423
6	RAW	20k	LogReg	0.7346	0.4820	0.6926
7	BAL	10k	Random forest	0.6387	0.4818	0.6565
8	BAL	20k	SGD hinge	0.6254	0.4792	0.6487
9	RAW	20k	ComplementNB	0.7104	0.4760	0.6942
10	BAL	10k	LogReg	0.6016	0.4726	0.6346
11	BAL	10k	SGD hinge	0.6212	0.4706	0.6452
12	BAL	10k	ComplementNB	0.6243	0.4680	0.6439
13	BAL	20k	ComplementNB	0.6185	0.4666	0.6395
14	BAL	20k	LinearSVC	0.5850	0.4636	0.6196
15	RAW	10k	ComplementNB	0.6909	0.4598	0.6818
16	BAL	10k	LinearSVC	0.5764	0.4550	0.6128
17	RAW	10k	SGD hinge	0.7185	0.4106	0.6460
18	RAW	20k	SGD hinge	0.7140	0.4000	0.6397
19	RAW	10k	Random forest	0.6519	0.2100	0.5263
20	RAW	20k	Random forest	0.6452	0.1834	0.5122

Najbolje rezultate ostvaruju linearni model LinearSVC , što je u skladu sa teorijskim očekivanjem da visoko-dimenzionalni i retki TF-IDF prostor pogoduje linearnoj separaciji klasa.

Uticaj balansiranja (RAW vs BAL). Balansiranje podataka ima značajan uticaj na distribuciju metrika: u RAW varijanti modeli postižu višu Accuracy, ali nižu F1-macro u pojedinim slučajevima. Nakon balansiranja, F1-macro se stabilizuje za većinu modela, ali uz pad Accuracy. Ovo je direktna posledica toga da BAL varijanta prisiljava model da jednako tretira sve klase. Random Forest u RAW varijanti postiže visoku Accuracy, ali veoma nizak F1-macro, jer model favorizuje dominantnu klasu 5. Ovo pokazuje da Accuracy nije pouzdana metrika kod neuravnoteženih podataka. Balansiranje značajno poboljšava F1-macro jer model počinje da prepoznaje i manjinske klase.

Uticaj veličine TF-IDF rečnika (10k vs 20k). Povećanje rečnika sa 10.000 na 20.000 osobina donosi blago poboljšanje F1-macro za linearne modele, ali razlika je manja od 1%, što ukazuje da model dostiže plato informacija već pri 10.000 osobina.



Slika 4: Poređenje F1-macro svih modela za cilj Score (TF-IDF 20k, RAW vs BAL)

Sa slike 4 jasno se uočava da LinearSVC postiže najviši F1-macro u RAW varijanti, dok Random Forest dramatično zaostaje zbog favorizovanja dominantne klase. Balansiranje podataka najviše pomaže Random Forest modelu i SGD modelu, dok kod LinearSVC dolazi do blagog pada F1-macro.

6.6.2 Optimizacija i validacija najboljeg modela

Na osnovu svih sprovedenih eksperimenata, **LinearSVC** sa TF-IDF 20k u RAW varijanti identifikovan je kao najbolji model i nad njim je sprovedena dodatna analiza.

Unakrsna validacija. Stabilnost modela proverena je pomoću stratifikovane 5-fold unakrsne validacije na trening skupu:

$$\text{F1-macro}_{\text{CV}} = 0.5150 \pm 0.0060 \quad (5)$$

Niska standardna devijacija potvrđuje da rezultati nisu posledica povoljne podele podataka, već stabilan signal modela.

Pretraga hiperparametara. Optimizacija hiperparametara sprovedena je primenom **GridSearchCV** sa 3-fold unakrsnom validacijom, nad sledećim parametrima:

- regularizacioni parametar: $C \in \{0.01, 0.1, 1, 10\}$,
- opseg n-grama: $\text{ngram_range} \in \{(1, 2), (1, 3)\}$,
- minimalna frekvencija termina: $\text{min_df} \in \{2, 5\}$.

Evaluirano je ukupno 16 kombinacija (48 fitova). Optimalni hiperparametri i odgovarajući CV rezultat prikazani su u Tabeli 2.

Tabela 2: Optimalni hiperparametri – LinearSVC (GridSearchCV)

Parametar	Vrednost
C	1
ngram_range	(1, 2)
min_df	2
CV F1-macro (3-fold)	0.5079

Vrednosti optimalnih parametara poklapaju se sa podrazumevanom konfiguracijom korišćenom u osnovnim eksperimentima, što potvrđuje da inicijalni izbor parametara nije bio slučajan već robustan.

6.6.3 Najinformativnije reči po klasama – cilj Score

Analiza koeficijenata LinearSVC modela (RAW, TF-IDF 20k) otkriva koje reči i bigrami najviše doprinose predikciji svake ocene.

Tabela 3: Top 10 najinformativnijih reči/bigrama po klasi (LinearSVC, ALL, TF-IDF 20k, RAW)

Klasa (Score)	Najinformativnije reči / bigrami
Score 1 (najlošije)	worst, terrible, awful, one star, disgusting, gross, horrible, yuck, rip, waste
Score 2	two star, nearly good, lacked, way sweet, unfortunately, disappointed, coffee weak, completely different, expires, sadly
Score 3 (neutralno)	three star, okay, ok, alright, however, usually love, inconsistent, nothing special, product expensive, good great
Score 4	four star, reason give, star, complaint, gave star, pretty good, say best, treat never, criticism, flavor strong
Score 5 (odlično)	best, great, amazing, love, awesome, excellent, five star, perfect, delicious, fantastic

Analiza top reči pruža nekoliko zanimljivih uvida. Klase 1 i 5 imaju veoma jasno definisan vokabular – negativne emocije (worst, terrible, disgusting) nasuprot pozitivnih (best, amazing, excellent) – što objašnjava visoke performanse modela na ovim klasama. Klase 3 i 4 imaju ambivalentan vokabular: klasa 3 sadrži i “good great” kao indikativnu reč, dok klasa 4 sadrži reči poput “complaint” i “criticism”, što ukazuje da korisnici koji daju ocenu 4 često naglašavaju sitne nedostatke uprkos generalnom zadovoljstvu. Bigrami poput “one star”, “two star”, “three star”, “four star” i “five star” su direktan signal jer korisnici eksplicitno pominju ocenu u tekstu. Napominjemo da su atributi `HelpfulnessDenominator` i `HelpfulnessNumerator` isturili na vrh liste za klase 1 i 5 respektivno – što potvrđuje određenu korelaciju između korisnosti recenzije i ocene, ali ovi atributi su numerički i ne menjaju zaključke o tekstualnoj analizi.

6.6.4 Rezultati nad Text-only skupom

Tabela 4 prikazuje rezultate nad isključivo tekstualnim atributima (bez numeričkih osobina), sa i bez SVD redukcije dimenzionalnosti.

Tabela 4: Rezultati klasifikacije – cilj Score, Text-only atributi


Dataset	TFIDF	Model	Accuracy	F1-macro	F1-weighted
RAW	TFIDF_20k	LinearSVC	0.7348	0.5190	0.7117
RAW	TFIDF_10k	LinearSVC	0.7313	0.5127	0.7064
BAL	TFIDF_20k	Random forest	0.6453	0.4864	0.6625
RAW	TFIDF_10k	LogReg	0.7352	0.4845	0.6946
RAW	TFIDF_20k	LogReg	0.7347	0.4824	0.6923
BAL	TFIDF_20k	SGD hinge	0.6266	0.4773	0.6501
BAL	TFIDF_20k	LogReg	0.6052	0.4761	0.6376
BAL	TFIDF_10k	SGD hinge	0.6290	0.4749	0.6515
RAW	TFIDF_20k	ComplementNB	0.7076	0.4746	0.6934
BAL	TFIDF_10k	Random forest	0.6344	0.4737	0.6529
BAL	TFIDF_10k	LogReg	0.5998	0.4703	0.6332
BAL	TFIDF_20k	ComplementNB	0.6152	0.4659	0.6375
BAL	TFIDF_10k	ComplementNB	0.6202	0.4651	0.6410
BAL	TFIDF_20k	LinearSVC	0.5842	0.4626	0.6190
RAW	TFIDF_10k	ComplementNB	0.6889	0.4583	0.6808
BAL	TFIDF_10k	LinearSVC	0.5742	0.4531	0.6107
RAW	TFIDF_10k	SGD hinge	0.7161	0.4068	0.6443
RAW	TFIDF_20k	SGD hinge	0.7151	0.4033	0.6421
RAW	TFIDF_10k	Random forest	0.6513	0.2081	0.5252
RAW	TFIDF_20k	Random forest	0.6447	0.1819	0.5112
<i>Sa SVD redukcijom (TF-IDF 10k + SVD $k=300$, explained variance = 31.6%)</i>					
RAW	SVD(300)	LogReg	0.7082	0.4019	0.6520
RAW	SVD(300)	LinearSVC	0.7068	0.3836	0.6440
RAW	SVD(300)	Random forest	0.6849	0.3412	0.5948
RAW	SVD(300)	SGD hinge	0.6895	0.3087	0.5976

Uticaj SVD redukcije dimenzionalnosti. Primena TruncatedSVD sa $k = 300$ komponenti objašnjava 31.6% ukupne varijanse, što dovodi do gubitka dela diskriminativnih informacija. Svi modeli beleže pad F1-macro u poređenju sa punim TF-IDF prostorom. Complement Naive Bayes je izostavljen iz SVD eksperimenta jer TruncatedSVD može proizvoditi negativne vrednosti u redukovanom prostoru, što narušava pretpostavku algoritma o nenegativnim frekvencijama reči. Linearni modeli gube najviše jer su suptilne razlike između klasa raspodeljene kroz hiljade retko aktivnih reči koje SVD tretira kao šum. Random Forest, uprkos teorijskom očekivanju da bi gušća reprezentacija trebalo da mu pomogne, takođe beleži pad – verovatno zato što 300 SVD komponenti još uvek ne pruža dovoljno čistu separaciju za stabla odlučivanja u ovom problemu.

6.6.5 Poređenje Text-only vs ALL atributi

Dodavanje numeričkih osobina donosi minimalno poboljšanje (manje od 0.3% F1-macro), što potvrđuje da tekstualni sadržaj nosi dominantnu informaciju za predikciju ocene.


6.6.6 Analiza matrica konfuzije – cilj Score



Slika 5: Matrice konfuzije – LinearSVC, ALL, TF-IDF 20k, cilj Score (RAW i BAL, train i test)

Iz slike 5 mogu se uočiti sledeći obrasci. U RAW varijanti, model na trening skupu postiže visoke vrednosti dijagonale (0.87–0.99), ali na test skupu dolazi do značajnog pada, posebno za srednje klase (klasa 1: 0.23, klasa 2: 0.34, klasa 3: 0.32). Ovo ukazuje na **overfitting** u RAW varijanti. Dominantna klasa 4 (ocena 5) postiže recall 0.93 na test skupu, što potvrđuje pristrasnost modela ka većinskoj klasi.


U BAL varijanti, trening skup pokazuje gotovo savršenu klasifikaciju (dijagonala $\approx$ 0.99–1.0), ali test skup otkriva izražen overfitting: vrednosti na dijagonali padaju na 0.43–0.64. Ovo je tipičan obrazac kod agresivnog undersampling-a – model uči balansirani skup napamet, ali gubi sposobnost generalizacije. Ipak, BAL varijanta ravnomernije raspodeljuje greške između klasa, što se odražava u višem F1-macro (0.464) u poređenju sa RAW varijantom LinearSVC (0.521 je bolje, ali BAL poboljšava klase sa slabim performansama).



Slika 6: Matrice konfuzije – Random Forest, ALL, TF-IDF 20k, cilj Score (RAW i BAL, train i test)

Slika 6 prikazuje najdramatičniji primer uticaja nebalansiranosti podataka. U RAW varijanti, model gotovo sve instance klasifikuje kao klasu 4 (ocena 5): recall za klase 0–3 je praktično nula, dok klasa 4 postiže recall 0.95–1.0 i na trening i na test skupu. Ovo objašnjava izuzetno nizak F1-macro (0.18) uprkos visokoj Accuracy (0.645) – model je naučio da uvek predviđa dominantnu klasu.

Nakon balansiranja (BAL), situacija se drastično menja: model počinje da prepoznaje sve klase, a dijagonala BAL TRAIN dostiže vrednosti 0.88–0.97. Na test skupu, BAL varijanta postiže znatno bolje rezultate za manjinske klase (klasa 0: 0.74, klasa 4: 0.73), ali uz povećanje grešaka između susednih ocena, što je inherentna teškoća ovog problema. Razlika između BAL TRAIN i BAL TEST ukazuje na određen stepen overfittinga, ali znatno manji nego u RAW varijanti.



Slika 7: Matrice konfuzije – LogReg, TF-IDF 10k + SVD(300), cilj Score (train i test)

Matrica konfuzije – LogReg sa SVD redukcijom. Slika 7 prikazuje rezultate najboljeg modela nakon SVD redukcije dimenzionalnosti ($k = 300$, objašnjeno 31.6% varijanse). Obrazac je sličan kao kod LinearSVC bez redukcije – model dobro prepoznaje dominantnu klasu 4 (recall 0.96–0.97), dok srednje klase ostaju problematične (klasa 1: 0.45 train, 0.48 test; klasa 2: 0.52 train, 0.51 test).

Poređenjem train i test matrice može se uočiti da su vrednosti gotovo identične, što ukazuje na **odsustvo overfittinga** – SVD redukcija efektivno smanjuje šum i sprečava memorisanje trening skupa. Međutim, apsolutne vrednosti dijagonale su niže nego kod LinearSVC bez SVD-a (klasa 0: 0.55 vs 0.63), što potvrđuje zaključak da redukcija na 300 komponenti gubi deo diskriminativnih informacija relevantnih za linearni model. Jedina klasa koja profitira od SVD-a jeste klasa 4, koja zadržava visok recall (0.96) uz minimalnu razliku između train i test skupa.

6.7 Rezultati za cilj *Sentiment*

Za razliku od cilja *Score*, klasifikacija *Sentiment*-a predstavlja binarni problem (negativno / pozitivno), što je metodološki jednostavniji zadatak i očekivano daje više metrike.

6.7.1 Rezultati nad ALL atributima

Tabela 5: Rezultati klasifikacije – cilj Sentiment, ALL atributi


Dataset	TFIDF	Model	Accuracy	F1-macro	F1-weighted
RAW	20k	LinearSVC	0.9397	0.8790	0.9380
RAW	10k	LinearSVC	0.9391	0.8783	0.9375
RAW	20k	ComplementNB	0.9202	0.8533	0.9215
BAL	20k	SGD hinge	0.9104	0.8498	0.9154
BAL	20k	LinearSVC	0.9059	0.8464	0.9122
BAL	10k	SGD hinge	0.9028	0.8420	0.9094
RAW	10k	LogReg	0.9282	0.8419	0.9223
BAL	10k	LinearSVC	0.9012	0.8397	0.9080
RAW	20k	LogReg	0.9274	0.8380	0.9208
RAW	10k	SGD hinge	0.9261	0.8338	0.9190
RAW	10k	ComplementNB	0.8979	0.8305	0.9041
RAW	20k	SGD hinge	0.9250	0.8300	0.9174
BAL	20k	ComplementNB	0.8968	0.8299	0.9033
BAL	10k	ComplementNB	0.8959	0.8294	0.9027
BAL	20k	LogReg	0.8934	0.8292	0.9012
BAL	10k	LogReg	0.8922	0.8276	0.9002
BAL	20k	Random forest	0.8837	0.8136	0.8922
BAL	10k	Random forest	0.8814	0.8119	0.8906
RAW	10k	Random forest	0.8622	0.5675	0.8131
RAW	20k	Random forest	0.8542	0.5214	0.7960

Najbolji rezultat postigao je LinearSVC sa TF-IDF 20k u RAW varijanti, što potvrđuje da linearni modeli najbolje odgovaraju visoko-dimenzijskim i retkim tekstualnim reprezentacijama.

Complement Naive Bayes postiže $F1\text{-macro} = 0.853$, što predstavlja značajno bolji rezultat nego u slučaju višeklasne klasifikacije cilja Score. Razlog je što u binarnom problemu distribucije reči između dve klase (pozitivno i negativno) postaju jasnije razdvojene, dok se kod većeg broja klasa razlike između njih preklapaju. Pošto Naive Bayes modelira raspodelu reči po klasama i oslanja se na pretpostavku uslovne nezavisnosti atributa, on prirodno bolje funkcioniše kada je broj klasa manji i granice između njih izraženije.

Uticaj balansiranja (RAW vs BAL). Za cilj Sentiment balansiranje ima ograničen efekat jer je početna neuravnoteženost klasa manja nego kod cilja Score. Kod LinearSVC dolazi do pada $F1\text{-macro}$ uz smanjenje Accuracy, što ukazuje da undersampling smanjuje količinu podataka za učenje i povećava varijansu modela.

Izuzetak je Random Forest, gde balansiranje značajno poboljšava performanse, jer model u RAW varijanti favorizuje većinsku klasu.



Slika 8: Poređenje F1-macro svih modela za cilj Sentiment (TF-IDF 20k, RAW vs BAL)

Za razliku od cilja Score (slika 4), kod Sentiment klasifikacije modeli su znatno ujednačeniji – F1-macro vrednosti su koncentrisane u opsegu 0.82–0.88 za sve modele osim Random Forest u RAW varijanti. Balansiranje ovde nema pozitivan efekat za većinu modela, što potvrđuje da su klase kod Sentiment-a manje neuravnotežene.


6.7.2 Rezultati nad Text-only skupom

Tabela 6: Rezultati klasifikacije – cilj Sentiment, Text-only atributi

Dataset	TFIDF	Model	Accuracy	F1-macro	F1-weighted
RAW	TFIDF_10k	LinearSVC	0.9378	0.8754	0.9361
RAW	TFIDF_20k	LinearSVC	0.9378	0.8752	0.9360
RAW	TFIDF_20k	ComplementNB	0.9225	0.8576	0.9237
RAW	TFIDF_10k	LogReg	0.9284	0.8422	0.9225
RAW	TFIDF_20k	LogReg	0.9276	0.8387	0.9211
BAL	TFIDF_20k	LinearSVC	0.9004	0.8383	0.9073
BAL	TFIDF_20k	SGD hinge	0.8991	0.8365	0.9061
BAL	TFIDF_10k	LinearSVC	0.8971	0.8339	0.9044
RAW	TFIDF_10k	SGD hinge	0.9251	0.8310	0.9178
BAL	TFIDF_10k	SGD hinge	0.8941	0.8296	0.9017
BAL	TFIDF_10k	ComplementNB	0.8952	0.8285	0.9021
BAL	TFIDF_20k	ComplementNB	0.8958	0.8283	0.9024
RAW	TFIDF_10k	ComplementNB	0.8956	0.8270	0.9019
BAL	TFIDF_20k	LogReg	0.8903	0.8252	0.8986
RAW	TFIDF_20k	SGD hinge	0.9236	0.8252	0.9154
BAL	TFIDF_10k	LogReg	0.8888	0.8234	0.8973
BAL	TFIDF_20k	Random forest	0.8746	0.8028	0.8847
BAL	TFIDF_10k	Random forest	0.8671	0.7922	0.8781
RAW	TFIDF_10k	Random forest	0.8597	0.5529	0.8077
RAW	TFIDF_20k	Random forest	0.8537	0.5188	0.7950

Rezultati Text-only konfiguracije su gotovo identični ALL konfiguraciji, što potvrđuje zaključak da numeričke osobine ne donose značajno poboljšanje ni za cilj Sentiment.


6.7.3 Analiza matrica konfuzije – cilj Sentiment



Slika 9: Matrice konfuzije – LinearSVC, ALL, TF-IDF 20k, cilj Sentiment (RAW i BAL, train i test)

Slika 9 pokazuje da LinearSVC u RAW varijanti postiže visoku tačnost na trening skupu (klasa 0: 0.96, klasa 1: 1.0), ali na test skupu dolazi do pada za negativnu klasu (recall 0.74), dok pozitivna klasa ostaje visoka (0.98). Ova asimetrija ukazuje da model u RAW varijanti blago favorizuje pozitivnu klasu zbog njene veće zastupljenosti.

BAL varijanta ispravlja ovu asimetriju – na test skupu obe klase postižu sličan recall (0.91), uz minimalan pad ukupne tačnosti. Razlike između train i test skupa su male u oba slučaja, što ukazuje na **dobru generalizaciju** LinearSVC modela za binarni problem.




Slika 10: Matrice konfuzije – Random Forest, ALL, TF-IDF 20k, cilj Sentiment (RAW i BAL, train i test)


Isti obrazac kao kod cilja Score ponavlja se i ovde: Random Forest u RAW varijanti klasifikuje gotovo sve instance kao pozitivne (klasa 1: recall = 1.0 na oba skupa), potpuno ignorišući negativnu klasu (klasa 0: recall = 0.14 train, 0.065 test). F1-macro je posledično nizak (0.52).

Nakon balansiranja, model znatno poboljšava prepoznavanje negativne klase (BAL TEST: klasa 0 = 0.87, klasa 1 = 0.89), uz minimalnu razliku između train i test skupa, što ukazuje na dobru generalizaciju BAL varijante.

6.7.4 ROC kriva i AUC metrika



Slika 11: ROC kriva – LinearSVC, ALL atributi (AUC = 0.9669)



Slika 12: ROC kriva – LinearSVC, Text-only atributi (AUC = 0.9656)

ROC krive na slikama 11 i 12 prikazuju performanse LinearSVC modela za binarnu klasifikaciju Sentiment-a. Oba modela postižu izuzetno visoke AUC vrednosti (ALL: 0.9669, Text-only: 0.9656), što potvrđuje da model ima odličnu sposobnost razlikovanja pozitivnih od negativnih recenzija.

Razlika između ALL i Text-only konfiguracije iznosi svega **0.0013**, što je zanemarljivo i ponovo potvrđuje da numeričke osobine ne donose merljivo poboljšanje. Krive imaju karakteristično strm uspon u levom delu dijagrama, što znači da model postiže visok True Positive Rate već pri vrlo niskom False Positive Rate – idealno ponašanje binarnog klasifikatora.

6.8 Poređenje cilja *Score* i cilja *Sentiment*

Tabela 7 sumira beste rezultate za oba cilja, radi direktnog poređenja.

Tabela 7: Poređenje najboljeg modela za Score i Sentiment

Cilj	Konfiguracija	Model	Accuracy	F1-macro	F1-weighted
Score	ALL, 20k, RAW	LinearSVC	0.7360	0.5212	0.7130
Sentiment	ALL, 20k, RAW	LinearSVC	0.9397	0.8790	0.9380
Razlika (Sentiment – Score)				+0.3578	+0.2250

Binarna klasifikacija (Sentiment) postiže znatno bolje rezultate od višeklasne (Score). Razlog je što je granica između pozitivnog i negativnog stava jasno izražena u tekstu, dok su razlike između susednih ocena suptilne, često subjektivne i lingvistički slične. Manji broj klasa dodatno olakšava učenje, što posebno dolazi do izražaja kod probabilističkih modela poput Naive Bayes, koji imaju poteškoće kada se raspodele reči između velikog broja klasa značajno preklapaju.

6.9 Zaključak klasifikacije

Na osnovu sprovedenih eksperimenata mogu se izvesti sledeći zaključci o prirodi problema i ponašanju algoritama.

Zašto linearni modeli dominiraju. LinearSVC i Logistic Regression konzistentno ostvaruju najbolje rezultate u svim konfiguracijama, i to nije slučajno. TF-IDF reprezentacija stvara prostor u kome svaka reč ili bigram odgovara jednoj dimenziji – takav prostor je visoko-dimenzionalan, redak i inherentno pogodan za linearnu separaciju. Linearni modeli direktno iskorišćavaju ovu strukturu: traže hiperravan koja razdvaja klase u celom prostoru reči, bez pokušaja da nauče nelinearne obrasce koji bi u ovakvom prostoru ionako bili lažni. Random Forest, nasuprot tome, pri svakom grananju razmatra samo podskup dimenzija – u prostoru od 20.000 reči gde je većina vrednosti nula, takav pristup često bira neinformativne dimenzije i donosi nestabilne odluke.

Zašto balansiranje pomaže nekim modelima, a drugima ne. Efekat balansiranja direktno zavisi od toga kako model reaguje na neuravnoteženost klasa. Random Forest u originalnoj distribuciji uči da je najsigurnije uvek predvideti ocenu 5, jer to minimizuje ukupnu grešku na skupu gde ta klasa čini 64% podataka – rezultat je model koji na papiru ima solidnu tačnost, ali u praksi ne klasifikuje ništa. Balansiranje primorava model da vidi jednako primera iz svake klase i time razbija ovu lažnu strategiju. Linearni modeli su po prirodi otporniji na ovaj problem jer optimizuju granicu između klasa, a ne ukupnu stopu grešaka – zbog toga balansiranje kod njih donosi manje poboljšanje, a ponekad čak i blagi pad jer se smanjuje ukupna količina podataka za učenje.

Zašto SVD redukcija škodi svim modelima u klasifikaciji. Linearni modeli gube informaciju: suptilne razlike između recenzija sa ocenom 3 i ocenom 4 nisu koncentrisane u nekoliko dominantnih dimenzija, već su raspodeljene kroz hiljade retko aktivnih reči – upravo te reči SVD baca kao šum, a one su ključne za fine razlike. Random Forest, nasuprot teorijskom očekivanju, takođe beleži pad – verovatno jer 300 SVD komponenti, iako gušće od retke matrice, u ovom problemu i dalje ne pruža dovoljno čistu separaciju da bi stabla odlučivanja mogla da nauče granice između susednih klasa (npr. ocena 3 vs. ocena 4). Ovo je bitna razlika u odnosu na klasterovanje, gde SVD pomaže – tamo se traže grupe, ovde se traže fine klasifikacione granice.

Zašto numeričke osobine gotovo ništa ne doprinose. Metrike korisnosti recenzije (koliko su je drugi korisnici ocenili kao korisnu) ne govore ništa o tome šta je u recenziji napisano niti kakav stav autor ima. Recenzija koja je veoma korisna može biti i pozitivna i negativna – taj atribut meri kvalitet pisanja, ne sentiment. Zbog toga dodavanje ovih osobina ne poboljšava predikciju ni ocene ni sentimenta.

Zašto je Sentiment lakši problem od Score. Razlika u performansama između binarnog i višeklasnog cilja nije samo posledica manjeg broja klasa, ona odražava suštinsku razliku u tome koliko je granica između klasa izražena u jeziku. Kada korisnik piše negativnu recenziju, to se jasno vidi u izboru reči: negativan vokabular je semantički daleko od pozitivnog. Razlika između ocene 3 i ocene 4, međutim, često nije jezička – isti tekst mogao je dobiti i jednu i drugu ocenu. Uklanjanje neutralnih recenzija (ocena 3) dodatno pojačava ovaj efekat, jer u skupu ostaju samo polarizovane recenzije sa jasnim signalom.

Overfitting kao sistemski obrazac. Matrice konfuzije otkrivaju da overfitting nije greška već očekivana posledica metodoloških izbora. Balansiranje agresivnim undersampling-om stvara mali trening skup koji model može naučiti napamet, ali koji ne reprezentuje pravu distribuciju test podataka. SVD redukcija, nasuprot tome, eliminiše overfitting time što kompaktni prostor ne pruža dovoljno detalja za memorisanje – ali po cenu nižih apsolutnih performansi. Za Sentiment problem jaz između trening i test skupa je manji, što potvrđuje da je binarni problem stabilniji: granica između klasa je toliko jasna da je model ne može značajno pregeneralizovati.

7 Klasterovanje

Klasterovanje je tehnika nenadgledanog mašinskog učenja kojom se podaci grupišu u klustere na osnovu međusobne sličnosti, bez unapred poznatih labela. U ovom radu primenjeno je klasterovanje nad stratifikovanim uzorkom od **10.000 recenzija** (stratifikacija po atributu **Score**) na tri različita skupa atributa:

- **Svi atributi** – kombinacija TF-IDF tekstualnih vektora i numeričkih atributa (Helpfulness),
- **Samo tekst** – isključivo TF-IDF vektori bez numeričkih atributa,
- **Redukovani atributi (SVD)** – TF-IDF vektori redukovani primenom Truncated SVD.

Za svaki skup atributa primenjeno je pet algoritama klasterovanja. Pored automatski određenog optimalnog broja klastera, za svaki skup primenjen je i model sa $K = 5$, što je domenski motivisano brojem mogućih ocena na Amazon platformi (1–5).

7.1 Metrike evaluacije

Kvalitet klasterovanja evaluiran je sledećim unutrašnjim metrikama koje ne zahtevaju poznavanje stvarnih labela:

- **Silhouette koeficijent** – meri koliko je tačka slična sopstvenom klasteru u poređenju sa ostalim klasterima. Vrednost bliža 1 ukazuje na jasno razdvojene klustere, vrednost bliža -1 na pogrešnu dodelu. Formula:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

gde je $a(i)$ prosečno rastojanje od tačaka u sopstvenom klasteru, a $b(i)$ prosečno rastojanje do tačaka najbližeg susednog klastera.

- **Davies-Bouldin indeks** – meri prosečnu sličnost između svakog klastera i njemu najbližijeg klastera. Niža vrednost ukazuje na bolje klasterovanje:

$$DB = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{\sigma_i + \sigma_j}{d(c_i, c_j)} \right)$$

- **Calinski-Harabasz indeks** – odnos između zbijenosti klastera i razdvojenosti klastera. Viša vrednost ukazuje na bolje definisane klastere:

$$CH = \frac{\text{tr}(B_k)}{\text{tr}(W_k)} \cdot \frac{n - k}{k - 1}$$

Silhouette koeficijent je računat korišćenjem **kosinusne mere rastojanja** (`metric=čosine`), što je prikladnije za TF-IDF vektore u visokodimenzionalnom prostoru.

7.2 Primenjeni algoritmi

7.2.1 K-Means

K-Means je iterativni algoritam koji deli skup podataka na K klastera minimizacijom unutarklasterske varijanse:

$$J = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

gde je μ_i centroid klastera C_i . Korišćeni parametri: `n_init=10`, `random_state=42`.

7.2.2 MiniBatch K-Means

MiniBatch K-Means je aproksimacija K-Means algoritma koja umesto celog skupa podataka koristi nasumično odabrane podskupove (mini-batch) u svakoj iteraciji, što značajno ubrzava konvergenciju uz minimalnu žrtvu tačnosti. Korišćeni parametri: `batch_size=100`, `n_init=10`.

7.2.3 Agglomerative Clustering

Hijerarhijsko aglomerativno klasterovanje počinje sa svakom tačkom kao zasebnim klasterom, a zatim iterativno spaja najbliže parove klastera sve dok se ne dostigne željeni broj K . Korišćen je Wardov kriterijum spajanja koji minimizuje varijansu unutar klastera.

7.2.4 Spectral Clustering

Spektralno klasterovanje koristi sopstvene vektore Laplasijana matrice sličnosti podataka za redukciju dimenzija, a zatim primenjuje K-Means u redukovanom prostoru. Pogodno je za pronalaženje klastera nepravilnih oblika koji nisu linearno separabilni. Korišćeni parametar: `affinity='nearest_neighbors'`.

7.2.5 DBSCAN

DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*) grupiše tačke koje su gusto smeštene zajedno i označava kao šum tačke koje se nalaze u retkim regionima. Za razliku od ostalih algoritama, ne zahteva unapred definisan broj klastera. Korišćeni parametri: `eps=0.4`, `min_samples=3`.

7.3 Određivanje optimalnog broja klastera


Optimalni broj klastera određen je kombinacijom **Elbow metode** (analiza inercije K-Means algoritma) i **Silhouette analize** za vrednosti K u opsegu od 2 do 15. Optimalni K odgovara "laktu" Elbow krive i maksimumu Silhouette krive.

7.4 Klasterovanje – svi atributi

7.4.1 Opis skupa atributa

Ovaj skup kombinuje TF-IDF tekstualne vektore (1000 dimenzija, `ngram_range=(1,2)`, `min_df=5`) sa numeričkim atributima `HelpfulnessNumerator`, `HelpfulnessDenominator` i `HelpfulnessRatio`. Ukupna dimenzionalnost ulaznog prostora iznosi 1003. Kombinovanjem tekstualnih i numeričkih obeležja model dobija informacije i o sadržaju recenzije i o njenom društvenom uticaju.

7.4.2 Određivanje optimalnog K



Slika 13: Elbow i Silhouette analiza za određivanje optimalnog K – svi atributi

Elbow kriva i Silhouette analiza jasno ukazuju na $K = 2$ kao optimalan broj klastera sa Silhouette vrednošću ≈ 0.579 . Silhouette koeficijent opada monotono od $K = 2$ nadalje, što ukazuje da Helpfulness atributi daju jak binarni signal koji dominantno određuje klaster strukturu. Pored automatski detektovanog optimuma, sprovedeno je i klasterovanje sa $K = 5$, motivisano domenskim znanjem – pet mogućih ocena na Amazon platformi.

7.4.3 Rezultati

Tabela 8: Rezultati klasterovanja – svi atributi


Algoritam	K	Silhouette	Davies-Bouldin	Calinski-Harabasz
KMeans (opt.)	2	0.5791	1.1753	7027.86
MiniBatchKMeans (opt.)	2	0.5790	1.1756	7027.46
Agglomerative (opt.)	2	0.5590	1.2122	6631.18
Spectral (opt.)	2	0.5775	1.1769	6986.69
DBSCAN*	10	0.5862	0.3139	40.30
KMeans (K=5)	5	0.0856	4.2733	2157.25
MiniBatchKMeans (K=5)	5	0.0851	4.7432	2111.15
Agglomerative (K=5)	5	0.2744	3.0762	2144.37
Spectral (K=5)	5	0.0807	1.9639	1983.28

*DBSCAN Silhouette vrednost je misleading – 96.3% tačaka označeno kao šum


7.4.4 Analiza DBSCAN rezultata

DBSCAN je pronašao 10 klastera, ali je **96.3% tačaka (9632 od 10000) označeno kao šum** (labela -1). Preostalih 368 tačaka raspoređeno je u 10 mikroklastera. Visok Silhouette skor od 0.586 je stoga varljiv jer se izračunava samo na osnovu tih 368 tačaka. Ovaj rezultat potvrđuje da TF-IDF prostor, čak i sa numeričkim atributima, nije pogodan za DBSCAN algoritam koji zahteva gustinu tačaka – u visokodimenzionalnom retkom prostoru gustina je ujednačena i DBSCAN ne može identifikovati smislene oblasti povećane gustine.


7.4.5 Vizualizacija



Slika 14: 2D PCA prikaz klastera (KMeans, $K = 2$) – svi atributi



Slika 15: t-SNE prikaz klastera (KMeans, $K = 2$) – svi atributi (uzorak 2000)



Slika 16: Distribucija Score po klasterima (KMeans, $K = 2$) – svi atributi

7.4.6 Interpretacija klastera ($K = 2$)

Dva dobijena klastera imaju sledeće karakteristike:

Tabela 9: Statistika klastera za $K = 2$ – svi atributi

Klaster	Broj recenzija	Prosečan Score	HelpfulnessRatio
0	4500	4.12	0.60
1	5500	4.23	0.007

Klaster 0 (4500 recenzija): recenzije sa visokim HelpfulnessRatio (0.60) i nešto nižom prosečnom ocenom (4.12). Ovo su detaljne, smišljene recenzije koje su korisnici zajednice prepoznali kao korisne – tzv. “ekspertske” recenzije.

Klaster 1 (5500 recenzija): recenzije sa gotovo nulnim HelpfulnessRatio (0.007) i nešto višom prosečnom ocenom (4.23). Ovo su kratke, generičke recenzije koje niko nije ocenio kao korisne – dominiraju opšte pozitivne fraze bez specifičnih detalja.

Ključni nalaz je da podela **nije zasnovana na sentimentu** – prosečne ocene su gotovo identične u oba klastera (≈ 4.1 – 4.2), što potvrđuje da klasterovanje razdvaja recenzije prema *tipu korisnika i korisnosti recenzije*. Atribut HelpfulnessRatio pokazao se kao presudni diskriminativni faktor – bez njega Silhouette koeficijent iznosi ≈ 0.23 , a sa njim ≈ 0.58 .

7.4.7 Interpretacija klastera ($K = 5$)

Model sa $K = 5$ pruža finiju podelu:

Tabela 10: Statistika klastera za $K = 5$ – svi atributi

Klaster	Broj recenzija	Prosečan Score	HelpfulnessRatio
0	877	3.68	0.755
1	4247	4.30	0.000
2	3156	4.36	0.594
3	670	3.04	0.287
4	1050	4.32	0.000


Klaster 3 sa prosečnim Score od samo 3.04 se izdvaja kao dominantno neutralne, kritičke recenzije. Klaster 0 predstavlja detaljne kritičke recenzije sa visokim HelpfulnessRatio (0.755), koje su korisnici smatrali korisnim uprkos nižim ocenama.

7.5 Klasterovanje – samo tekst

7.5.1 Opis skupa atributa

Ovaj skup koristi isključivo TF-IDF vektore (1000 dimenzija) bez numeričkih atributa, čime se istražuje informacija sadržana samo u tekstu recenzija, bez uticaja Helpfulness signala.

7.5.2 Određivanje optimalnog K



Slika 17: Elbow i Silhouette analiza za određivanje optimalnog K – samo tekst

Silhouette kriva je testirana u opsegu K od 2 do 15. Za razliku od skupa sa svim atributima, kriva monotonno raste kroz ceo testirani opseg bez jasnog maksimuma – vrednosti Silhouette rastu od 0.019 za $K = 2$ do 0.047 za $K = 15$. Ovakvo ponašanje ukazuje da čisto tekstualni TF-IDF prostor nema izraženu prirodnu klasterSKU strukturu. Radi interpretabilnosti rezultata, optimalni K je ograničen na $K = 8$.

7.5.3 Rezultati

Tabela 11: Rezultati klasterovanja – samo tekst


Algoritam	K	Silhouette	Davies-Bouldin	Calinski-Harabasz
KMeans ($K=8$)	8	0.0377	7.5293	75.94
MiniBatchKMeans ($K=8$)	8	0.0333	6.8533	69.52
Agglomerative ($K=8$)	8	0.0124	4.6953	57.99
Spectral ($K=8$)	8	-0.0075	3.2136	26.73
DBSCAN*	14	0.9272	0.0993	761.14
KMeans ($K=5$)	5	0.0323	6.5530	96.59
MiniBatchKMeans ($K=5$)	5	0.0316	5.5095	95.33
Agglomerative ($K=5$)	5	0.0132	5.2263	75.04
Spectral ($K=5$)	5	-0.0113	2.8731	21.19

*DBSCAN Silhouette vrednost je misleading – 99.6% tačaka označeno kao šum


7.5.4 Analiza DBSCAN rezultata

Situacija sa DBSCAN-om je još drastičnija nego u slučaju svih atributa – **99.6% tačaka (9956 od 10000) je označeno kao šum**. Ovo konzistentno potvrđuje da TF-IDF prostor bez redukcije dimenzionalnosti nije pogodan za DBSCAN.

7.5.5 Vizualizacija



Slika 18: t-SNE prikaz klastera (KMeans, $K = 8$) – samo tekst (uzorak 2000)



Slika 19: t-SNE prikaz klastera (KMeans, $K = 5$) – samo tekst (uzorak 2000)

7.5.6 Interpretacija klastera ($K = 8$)

Ključna prednost tekst-only klasterovanja je bogata tematska interpretacija klastera:

Tabela 12: Top reči po klasterima za $K = 8$ – samo tekst

Klaster	Top reči
0	love, great, good, amazon, store, price, just, time, buy, best
1	dog, treat, food, dog love, love, dog food, like, chew, great, product
2	tea, green tea, green, flavor, taste, like, good, drink, bag, cup
3	cat, food, cat food, cat love, eat, like, love, canned, treat, chicken
4	bar, chocolate, peanut, taste, like, good, peanut butter, butter, snack, love
5	product, great, good, price, great product, use, love, taste, amazon, like
6	coffee, cup, flavor, like, strong, taste, good, bold, roast, cup coffee
7	taste, like, flavor, good, chip, just, water, great, really, drink

Model jasno identifikuje tematske kategorije proizvoda: kafa (klaster 6), čaj (klaster 2), mačja hrana (klaster 3), pseća hrana (klaster 1) i čokolada i grickalice (klaster 4). Ovo je fundamentalno drugačiji tip klasterovanja od prethodnog – umesto tipova korisnika, model pronalazi **kategorije proizvoda**.

Distribucija ocena po klasterima je gotovo uniformna – svi klasteri imaju oko 60–68% recenzija sa ocenom 5, što znači da tekst-only klasterovanje **ne razdvaja recenzije po sentimentu**, već isključivo po tematici. Ovo ilustruje ključnu razliku između dva pristupa: svi atributi vrše *bihevioralnu segmentaciju*, dok samo-tekstualni pristup vrši *tematsku segmentaciju*.

7.6 Klasterovanje – redukovani atributi (SVD)

7.6.1 Opis skupa atributa i SVD redukcija


U ovom eksperimentu primenjena je Truncated SVD (Singular Value Decomposition) redukcija dimenzionalnosti na TF-IDF vektore. SVD je ekvivalent PCA za sparse matrice i osnova je LSA (Latent Semantic Analysis) metode koja se koristi za otkrivanje latentnih tema u tekstu.

TF-IDF matrica dimenzionalnosti $n \times 5000$ redukovana je na $n \times 100$ primenom `TruncatedSVD(n_components=100)`:

$$X \approx U_k \Sigma_k V_k^T, \quad k = 100$$

Redukovana matrica $X_{\text{red}} = U_k \Sigma_k$ koristi se kao ulaz za algoritme klasterovanja. Dobijenih 100 komponenti objašnjava **20.8% varijanse** originalne matrice, što je tipično za sparse tekstualne podatke – informacija je rasuta po hiljadama dimenzija i svaka komponenta nosi relativno mali deo ukupne varijanse.

7.6.2 Određivanje optimalnog K



Slika 20: Elbow i Silhouette analiza za određivanje optimalnog K – redukovani atributi (SVD)

Silhouette kriva je testirana u opsegu K od 2 do 15. Kriva ima lokalni maksimum na $K = 14$ sa vrednošću ≈ 0.13 , što je trostruko više nego u slučaju samo teksta. Optimalni K je ograničen na $K = 8$ radi konzistentnosti sa prethodnim modelom i interpretabilnosti.

7.6.3 Rezultati

Tabela 13: Rezultati klasterovanja – redukovani atributi (SVD)


Algoritam	K	Silhouette	Davies-Bouldin	Calinski-Harabasz
KMeans (K=8)	8	0.1056	4.3226	220.73
MiniBatchKMeans (K=8)	8	0.1004	4.3352	206.11
Agglomerative (K=8)	8	0.0744	3.2202	184.04
Spectral (K=8)	8	0.0586	2.6803	136.47
DBSCAN*	30	0.6769	0.6178	60.77
KMeans (K=5)	5	0.0907	2.9910	277.27
MiniBatchKMeans (K=5)	5	0.0878	5.3740	257.04
Agglomerative (K=5)	5	0.0658	3.0436	237.46
Spectral (K=5)	5	0.0345	2.4111	134.28

*DBSCAN Silhouette vrednost je misleading – 98.2% tačaka označeno kao šum


7.6.4 Analiza DBSCAN rezultata

DBSCAN je pronašao 30 klastera, ali je **98.2% tačaka označeno kao šum**. SVD redukcija nije poboljšala prikladnost DBSCAN-a za ovaj tip podataka, što konzistentno potvrđuje nepodesnost algoritma za TF-IDF zasnovane prostore.

7.6.5 Vizualizacija



Slika 21: 2D PCA prikaz klastera (KMeans, $K = 8$ i $K = 5$) – redukovani atributi (SVD)



Slika 22: t-SNE prikaz klastera (KMeans, $K = 8$ i $K = 5$) – redukovani atributi (SVD, uzorak 2000)

7.6.6 Interpretacija klastera ($K = 8$)

SVD redukcija pruža čistiju tematsku separaciju nego sirovi TF-IDF:

Tabela 14: Top reči po klasterima za $K = 8$ – redukovani (SVD)

Klaster	Top reči
0	great, love, amazon, just, good, store, price, time, make, best
1	taste, like, flavor, good, just, chip, really, water, drink, dont
2	tea, green tea, green, flavor, taste, like, good, drink, bag, cup
3	dog, treat, food, love, dog love, dog food, like, chew, great, product
4	coffee, cup, flavor, like, strong, taste, good, bold, cup coffee, blend
5	bar, chocolate, taste, good, like, snack, love, dark, dark chocolate, flavor
6	product, great, good, great product, price, use, amazon, like, taste, love
7	cat, food, cat food, cat love, eat, love, like, canned, chicken, treat


SVD model sa $K = 8$ uspeva da **razdvoji mačju (klaster 7) i pseću hranu (klaster 3)** u zasebne klasterne, dok model sa $K = 5$ spaja ove dve kategorije. SVD klasterovanje postiže vrednosti Silhouette koeficijenta koje su **trostruko više** u odnosu na čisto tekstualno klasterovanje (≈ 0.106 nasuprot ≈ 0.037), što potvrđuje da redukcija dimenzionalnosti značajno poboljšava klasteru strukturu eliminacijom šuma. PCA vizualizacija pokazuje jasno odvojene “krakove” u prostoru prve dve glavne komponente – vidljivo poboljšanje u odnosu na samo-tekstualni pristup.

7.7 Poređenje modela klasterovanja


7.7.1 Poređenje po metrikama

Tabela 15: Uporedno poređenje svih skupova atributa (KMeans, bez DBSCAN)

Skup atributa	Prosečni Silhouette	Pobednički algoritam	Silhouette pobednika
Svi atributi	0.421	KMeans ($K = 2$)	0.579
Samo tekst	0.022	KMeans ($K = 8$)	0.038
Redukovani (SVD)	0.082	KMeans ($K = 8$)	0.106



Slika 23: Poređenje Silhouette Score svih algoritama kroz tri pristupa (DBSCAN izostavljen)



Slika 24: Distribucija Silhouette Score po skupu atributa (svaka tačka = jedan algoritam)

7.7.2 Ključni zaključci poređenja

Uticaj numeričkih atributa: Skup svih atributa pokazuje dramatično bolje metrike (Silhouette ≈ 0.58) u poređenju sa tekst-only skupom (≈ 0.038). Ovo ukazuje da HelpfulnessRatio nosi jak signal koji jasno razdvaja dve grupe recenzija.

Uticaj SVD redukcije: Redukovani skup postiže trostruko bolje metrike od tekst-only skupa (0.106 vs 0.038), što potvrđuje da SVD uspešno uklanja šum i pronalazi

latentne semantičke dimenzije u tekstu.

Tip klasterovanja: Svi atributi pronalaze *tipove korisnika* (korisne vs. nekorisne recenzije), dok tekst-only i SVD modeli pronalaze *kategorije proizvoda* (kafa, čaj, pseća hrana itd.). Ova razlika u tipu pronađene strukture je ključni zaključak rada.

Pobednički algoritam: KMeans konzistentno daje najbolje metrike u svim skupovima atributa. MiniBatchKMeans daje identične ili minimalno lošije rezultate uz znatno brže izvršavanje.

DBSCAN: Konzistentno neprikladan za sve tri konfiguracije podataka, sa 96–99% tačaka označenih kao šum. TF-IDF baziran prostor, čak i sa redukcijom dimenzionalnosti, nije dovoljno gust za DBSCAN.

7.8 Zaključak klasterovanja

Tri sprovedena pristupa klasterovanja otkrivaju različite aspekte strukture podataka, ilustrujući fundamentalni princip: *izbor ulaznih obeležja određuje kakve strukture model može da otkrije*.

Pristup sa svim atributima dominira po metrikama zahvaljujući signalu atributa HelpfulnessRatio i otkriva **bihevioralnu segmentaciju** – dve grupe korisnika koje se razlikuju po obrascu pisanja i korisnosti recenzije, a ne po sentimentu.

Samo-tekstualni pristup daje najniže numeričke metrike, ali otkriva smislene **tematske kategorije** – kafa, čaj, pseća i mačja hrana. Monotono rastuća Silhouette kriva potvrđuje odsustvo prirodne klusterske strukture u čistom TF-IDF prostoru, ali klasteri su lingvistički koherentni i domenski interpretabilni.

SVD pristup postiže kompromis: metrike su trostruko bolje od čisto tekstualnog pristupa, a tematske kategorije su čistije i jasnije razdvojene, sa vidljivo boljom vizuelnom separacijom u PCA i t-SNE projekcijama.

KMeans je konzistentno najstabilniji algoritam. DBSCAN je nepogodan za TF-IDF zasnovane prostore zbog fenomena prokletstva dimenzionalnosti. Dobre numeričke metrike nisu uvek znak bogatog uvida – domenski smisljena interpretacija jednako je važna za sveobuhvatnu evaluaciju klasterovanja.

8 Pravila pridruživanja

U ovom poglavlju primenjen je Apriori algoritam radi otkrivanja asocijativnih pravila između proizvoda na osnovu korisničkih recenzija na Amazon platformi. Cilj analize je identifikovanje proizvoda koje isti korisnici često ocenjuju zajedno, što može biti korisno za razumevanje obrazaca korisničkih preferencija i izgradnju sistema preporuka.

8.1 Formiranje transakcija

Transakcije su formirane tako što je za svakog korisnika (UserId) napravljen skup jedinstvenih proizvoda (ProductId) koje je ocenio. Duplikati (isti korisnik – isti proizvod) su uklonjeni pre formiranja transakcija.

Od ukupno **40.243 korisnika** u uzorku, **34.481** (85.7%) ocenilo je samo jedan proizvod i isključeno je iz analize. Nakon filtriranja, zadržano je **5.762 transakcija** korisnika sa najmanje dva različita ocenjena proizvoda.

8.2 Apriori algoritam i parametri

Apriori algoritam je primenjen sa sledećim parametrima:

- **min_support** = 0.001 (par proizvoda mora se pojaviti u najmanje 0.1% transakcija),
- **max_len** = 2 (traženi su samo parovi proizvoda),
- **min_lift** = 1.1 (pravilo mora pokazivati pozitivnu korelaciju).

Algoritam je pronašao **601** čest skup stavki, od čega **32** para proizvoda. Nakon primene lift praga, generisano je ukupno **64** asocijativna pravila.

8.3 Rezultati


Tabela 16 prikazuje top 10 asocijativnih pravila sortiranih po lift vrednosti. Svi proizvodi su identifikovani internim Amazon ProductId kodovima.

Tabela 16: Top 10 asocijativnih pravila (sortirano po lift vrednosti)

Antecedent (ako ocenjuje)	Consequent (onda ocenjuje)	Support	Confidence	Lift
B000KV7ZGQ	B000KV61FC	0.00139	0.800	460.96
B000KV61FC	B000KV7ZGQ	0.00139	0.800	460.96
B001VIY8BW	B003WK0D8O	0.00104	0.667	426.81
B003WK0D8O	B001VIY8BW	0.00104	0.667	426.81
B007Y59HVM	B005ZBZLT4	0.00104	0.600	345.72
B005ZBZLT4	B007Y59HVM	0.00104	0.600	345.72
B0029ZAOW8	B003QNJYXM	0.00122	0.700	336.12
B003QNJYXM	B0029ZAOW8	0.00122	0.583	336.12
B001J9QBU4	B003JA5KLM	0.00104	0.667	320.11
B003JA5KLM	B001J9QBU4	0.00104	0.500	320.11


Najjače pravilo je **B000KV7ZGQ** $\Rightarrow$ **B000KV61FC** sa lift vrednošću 460.96 i confidence 0.80 – korisnici koji su ocenili ovaj proizvod u 80% slučajeva ocenjuju i drugi, pri čemu je ta ko-pojava 461 puta češća nego što bi bila slučajna. Pravilo važi simetrično u oba smera, što ukazuje na jaku međusobnu vezanost ova dva proizvoda.

Sve lift vrednosti u top 10 su visoke (320–461), što ukazuje na snažnu pozitivnu asocijaciju. Ovakve vrednosti su tipične kada support nije velik ali je ko-pojava visoko koncentrisana unutar malog broja korisnika koji su ocenili oba proizvoda.



Slika 25: Pravila pridruživanja: Support vs Confidence (boja = Lift vrednost)

Scatter plot na slici 25 prikazuje sva 64 pravila u prostoru support–confidence, gde je lift kodiran bojom (žuto = visok lift). Može se uočiti da pravila sa najvišim lift vrednostima imaju visok confidence (0.7–0.8) ali relativno nizak support (≈ 0.0014), što je karakteristično za nišne proizvode koji se retko ocenjuju ali uz visoku međusobnu korelaciju. Pravila sa višim support vrednostima generalno imaju niži lift, što odražava poznatu inverznu vezu između ove dve metrike.



Slika 26: Mrežni dijagram povezanosti proizvoda (top 10 pravila, debljina ivice = confidence)

Mrežni dijagram na slici 26 vizuelno potvrđuje strukturu pronađenih pravila. Uočava

se da su parovi izolovani jedni od drugih – ne postoji centralni proizvod koji je povezan sa svima, već nekoliko nezavisnih parova sa jakom međusobnom vezom. Debljina ivica je proporcionalna confidence vrednosti pravila.

8.4 Zaključak pravila pridruživanja

Apriori analiza pokazuje da asocijativna pravila postoje ali su ograničena na uzak skup korisnika koji aktivno ocenjuju više proizvoda (14.3% od ukupnih). Pronađena pravila su smisljena – parovi proizvoda sa najjačim asocijacijama verovatno pripadaju istoj kategoriji ili marci, što potvrđuje validnost metodologije. Visoke lift vrednosti uz nizak support sugerišu da su veze nišne ali pouzdane, korisne za sisteme preporuka u segmentu aktivnih korisnika.

9 Zaključak rada

Realizovana je kompletna analiza nad skupom *Amazon Fine Food Reviews* primenom nadgledanih i nenadgledanih tehnika istraživanja podataka. Najstabilnije rezultate za klasifikaciju daju linearni modeli (LinearSVC, Logistic Regression), dok balansiranje utiče na F1-macro primarno kod Random Forest modela u višeklasnom problemu. Kod klasterovanja, izbor atributa određuje prirodu otkrivene strukture – numerički atributi otkrivaju bihevioralne obrasce korisnika, a čist tekst tematske kategorije proizvoda. SVD redukcija poboljšava klasterku strukturu eliminacijom šuma, dok se DBSCAN pokazao nepodesnim za visoko-dimenzionalne TF-IDF prostore. Apriori analiza pruža uvid u povezanost proizvoda kroz korisničke transakcije, sa najjačom asocijacijom između proizvoda iste marke i kategorije.

Svi eksperimenti realizovani su u Python okruženju korišćenjem biblioteka `pandas`, `numpy`, `scikit-learn`, `nltk`, `matplotlib`, `seaborn`, `plotly` i `mlxtend`. Kod je organizovan u notebook fajlovima: `classification*.ipynb`, `clustering*.ipynb` i `apriori.ipynb`.